오픈소스 기반 데이터분석

01강

데이터 분석과 오픈소스의 이해

컴퓨터과학과 정재화교수



학습목차

1. 데이터 분석의 이해
2. 데이터의 특징과 유형
3. 오픈소스의 이해



01

데이터 분석의 이해



데이터와 정보

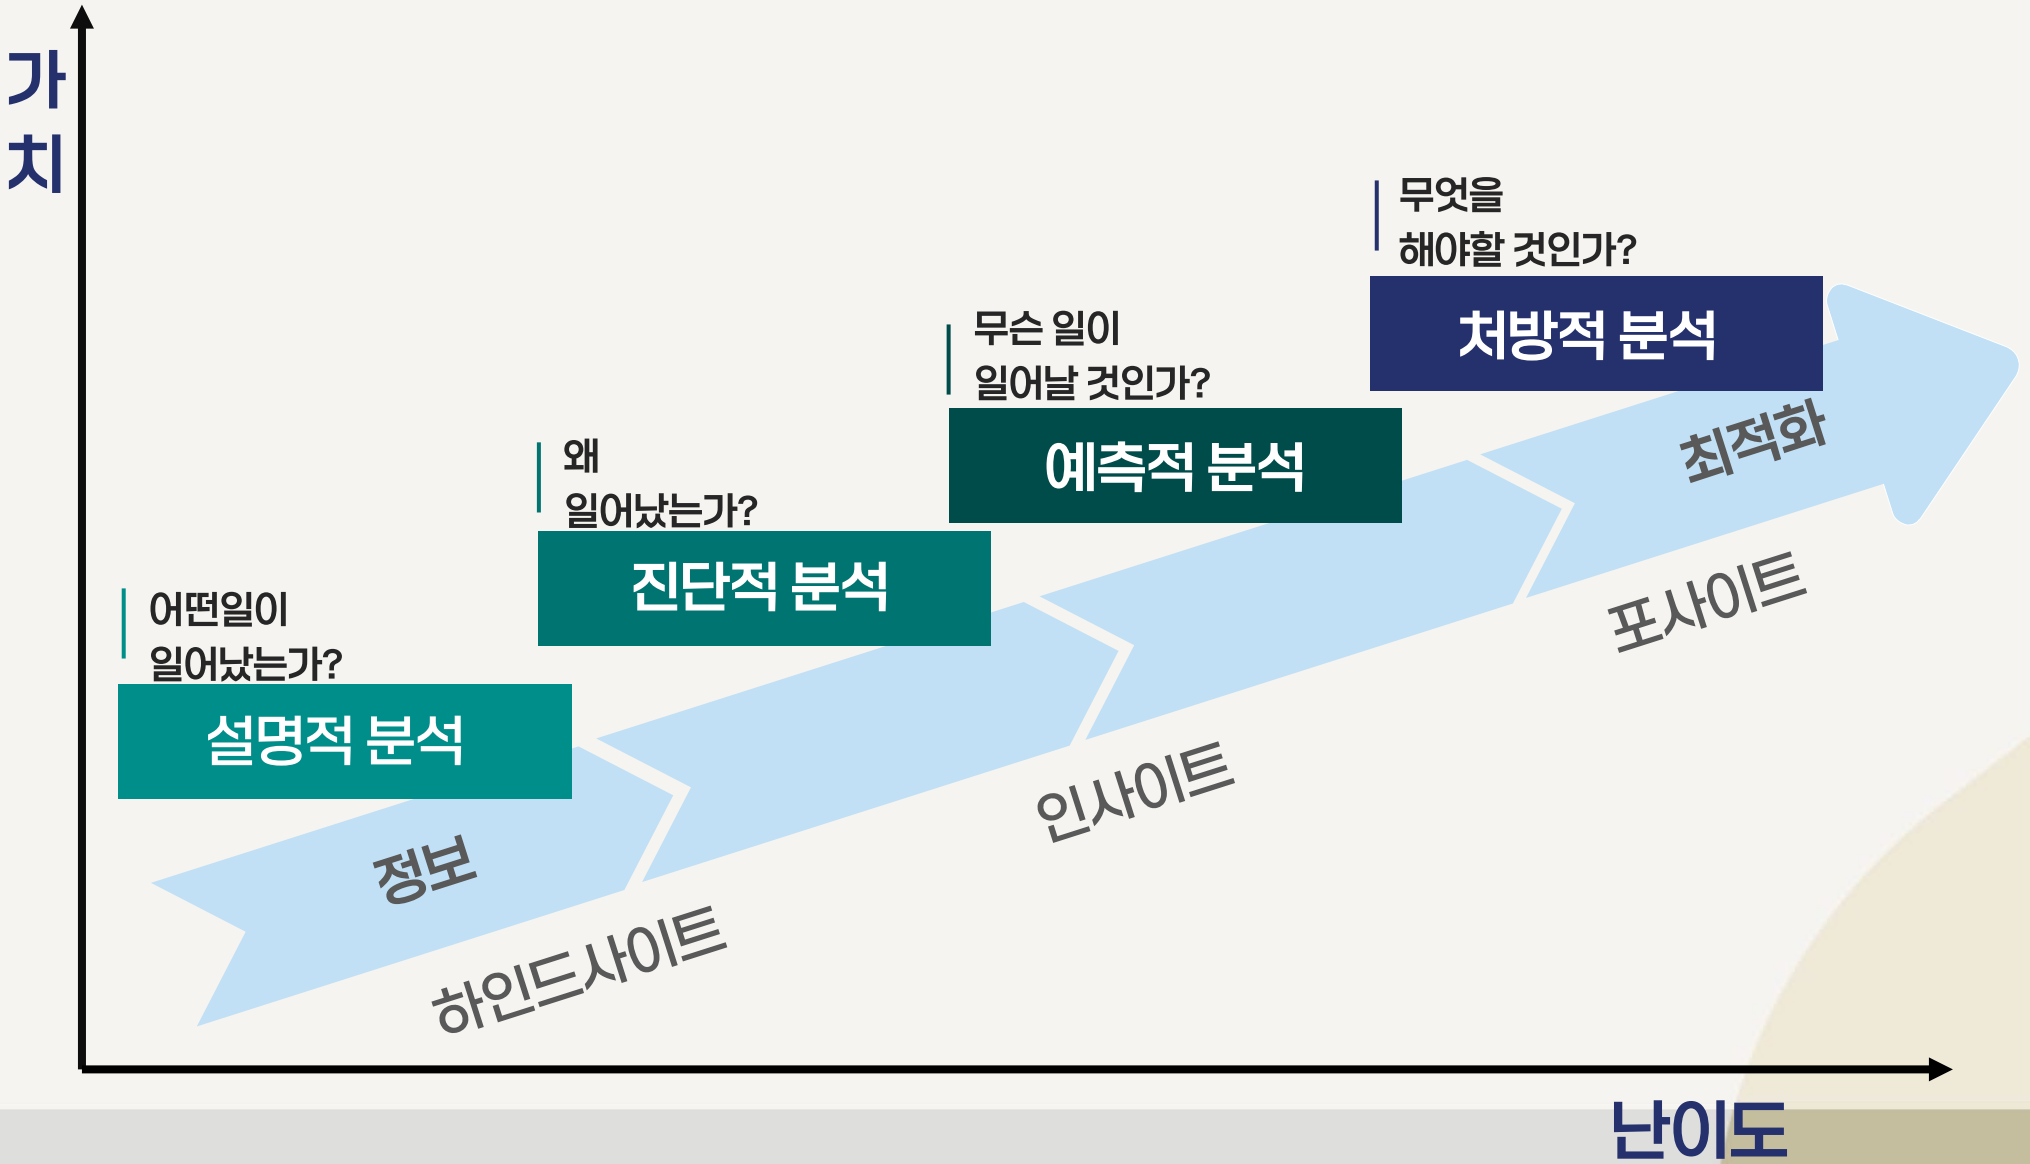
- 데이터 정의
  - 데이터에 숨겨진 의미를 발견하고, 이를 바탕으로 의사결정에 활용할 수 있는 인사이트를 도출하는 일련의 과정
- 정보의 정의
  - 정보는 데이터를 목적에 맞게 가공한 결과물



데이터 분석의 개념

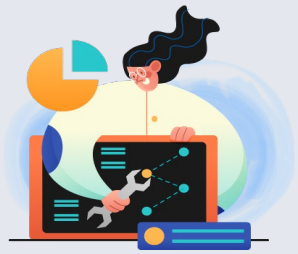
- 데이터에 숨겨진 의미를 발견하고, 이를 바탕으로 의사결정에 활용할 수 있는 인사이트를 도출하는 일련의 과정
  - 데이터를 정리·처리·변환하여 유의미한 정보를 도출
  - 데이터를 구조화하고 패턴을 파악하며, 특정 현상의 원인을 찾거나 미래를 예측하기 위한 논리적이고 체계적인 접근
  - 데이터에 감춰진 가치와 인사이트를 발견
- 의사결정의 질 향상 및 비즈니스 문제의 근본 원인 파악
- 데이터 품질 문제, 데이터의 규모와 복잡성, 적절한 분석 방법론 선택, 분석 결과 해석과 커뮤니케이션, 데이터 윤리와 개인정보 보호 등 다양한 도전 과제가 존재

데이터 분석의 4단계


가치
어떤일이 일어났는가?
설명적 분석
왜 일어났는가?
진단적 분석
무슨 일이 일어날 것인가?
예측적 분석
무엇을 해야할 것인가?
처방적 분석
정보
하인드사이트
인사이트
포사이트
최적화
난이도

데이터 분석 적용 사례: PHM

- 장비나 시스템의 상태를 실시간으로 감시하고, 고장 가능성을 예측하여 최적의 유지보수 및 관리 방안을 제공

STEP 01	STEP 02	STEP 03	STEP 04	STEP 05
				
계측 자동차에서 발생하는 다양한 데이터 수집	**모니터링** 정상 범위를 벗어나는 이상 징후 탐지	**진단** 구체적인 고장의 원인과 영향분석	**예측** 진단 정보를 바탕으로 향후 고장 가능성 판단	**개선** 최적의 개선책과 유지보수 전략 결정

(출처: 한국 PHM 학회)

데이터 분석 적용 사례

구분	주요 사례
개인 맞춤형 마케팅	전자상거래에서 스포츠 브랜드 신제품 추천
금융	은행의 대출 프로세스 자동화
스포츠	오클랜드 애슬레틱스 '머니볼 전략'
공공 정책	코로나19 대응 정책, 백신 계획
운영	제조업의 스마트 팩토리
의료	암 환자 맞춤형 치료법 개발
도시 행정 및 치안	교통 신호 체계 설계, 치안 개선

데이터 분석의 발전 과정

전통적인 통계 분석

- 확률론과 가설 검정 기법을 이용
- 데이터를 해석하는 방식

빅데이터와 ML의 발전

- 데이터의 규모와 다양성이 증가
- 오픈소스 프레임워크 개발
- 맞춤형 마케팅 수행



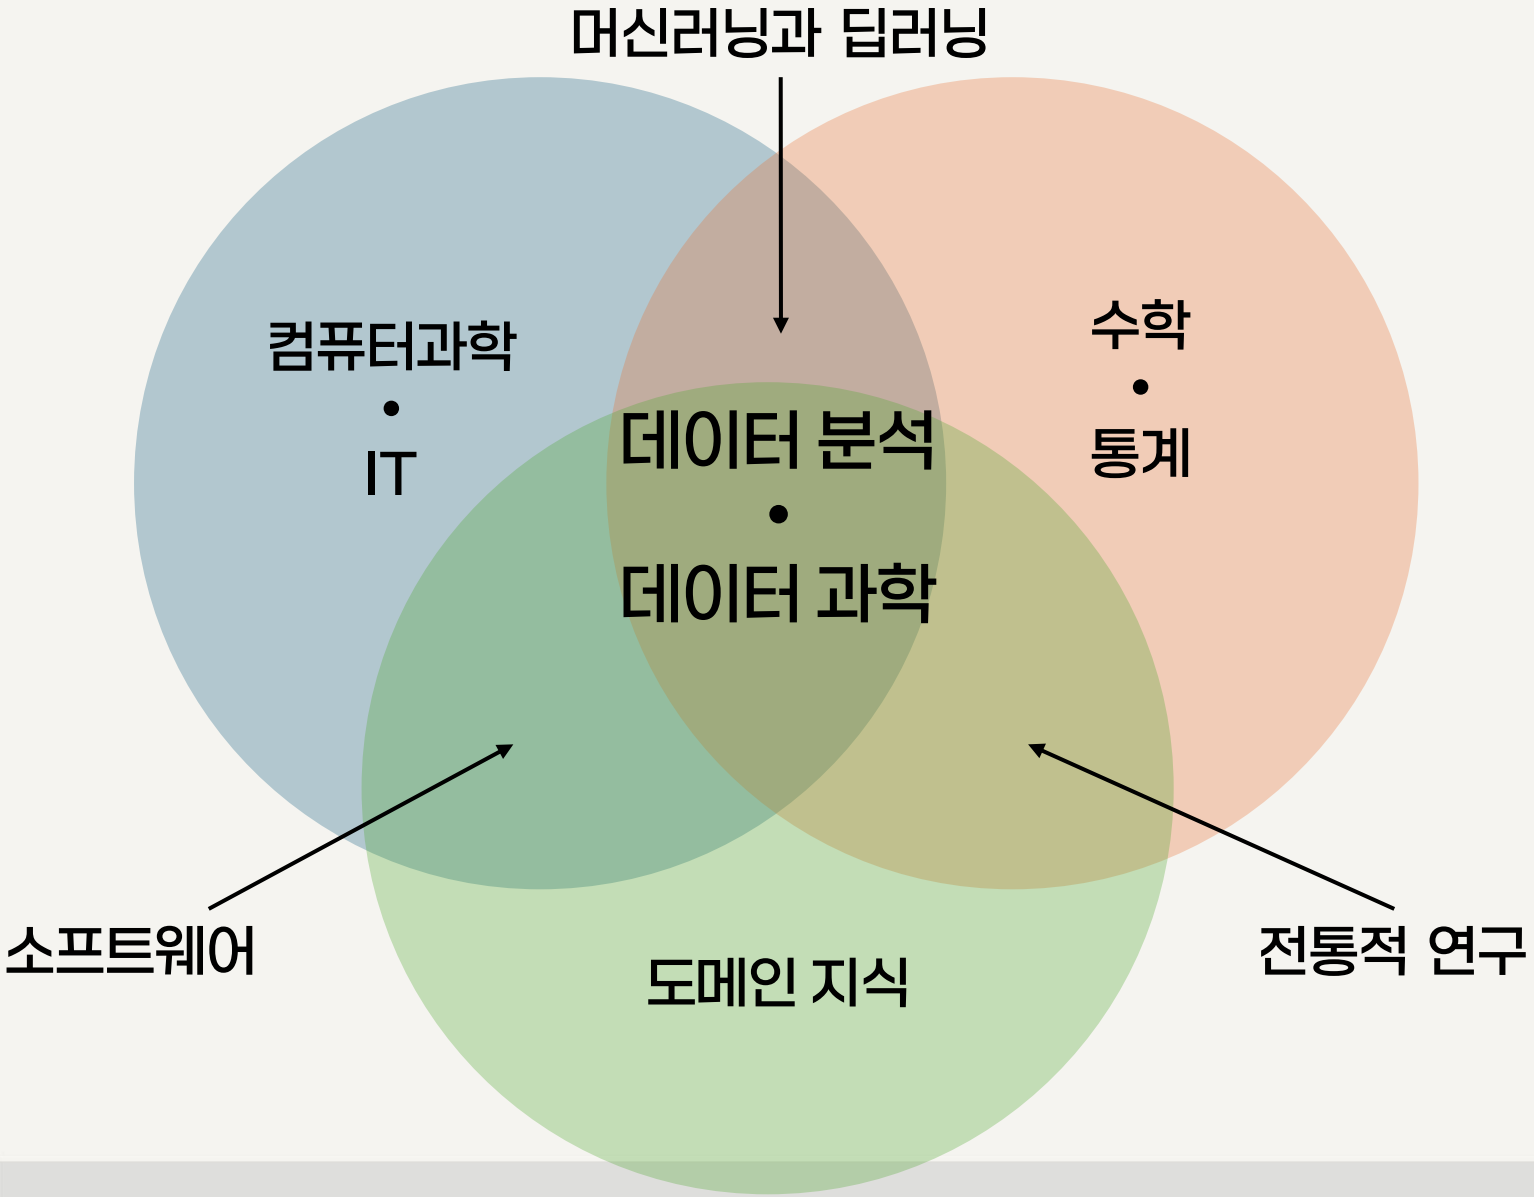
데이터베이스와 BI 활용

- DBMS를 도입
- 구조화된 데이터 분석 방식 전환
- 시각적으로 표현하는 BI 도구 도입

현재~미래

- 실시간 데이터 수집 및 분석
- 즉각적인 의사결정 시스템을 구축

데이터 분석의 3요소



데이터 분석과 데이터 과학

항목	데이터 분석	데이터 과학
개념	수집된 데이터를 정리·가공하여 의미 있는 정보를 도출하는 과정	예측 모델을 만들고, 자동화된 의사결정 시스템을 구축하는 포괄적 과정
접근 방식	통계, 데이터 시각화, 기본적인 머신러닝 등을 활용	통계, 머신러닝, 컴퓨터 프로그래밍, 데이터 엔지니어링 등을 종합적으로 활용
목적	데이터 기반 의사결정 지원이 중심	의사결정의 자동화 및 최적화
범위	데이터 과학의 한 부분	데이터 분석을 포함하는 상위 개념
과정	데이터 수집 → 전처리 → EDA → 분석→ 시각화 → 인사이트 도출	데이터 수집 → 전처리 → 분석 → 자동화 시스템 구현
분야	마케팅, 리포트 작성, 경영 전략 수립 등	제품 추천, 예측 시스템, 자율주행, 인공지능 서비스 등

02

데이터의 특징과 데이터 분석 과정



데이터 분석 과정

- 데이터를 적절한 방법으로 수집하고 정제한 후, 패턴을 탐색하고 모델링을 수행하여 결과를 해석하는 체계적인 접근이 필요

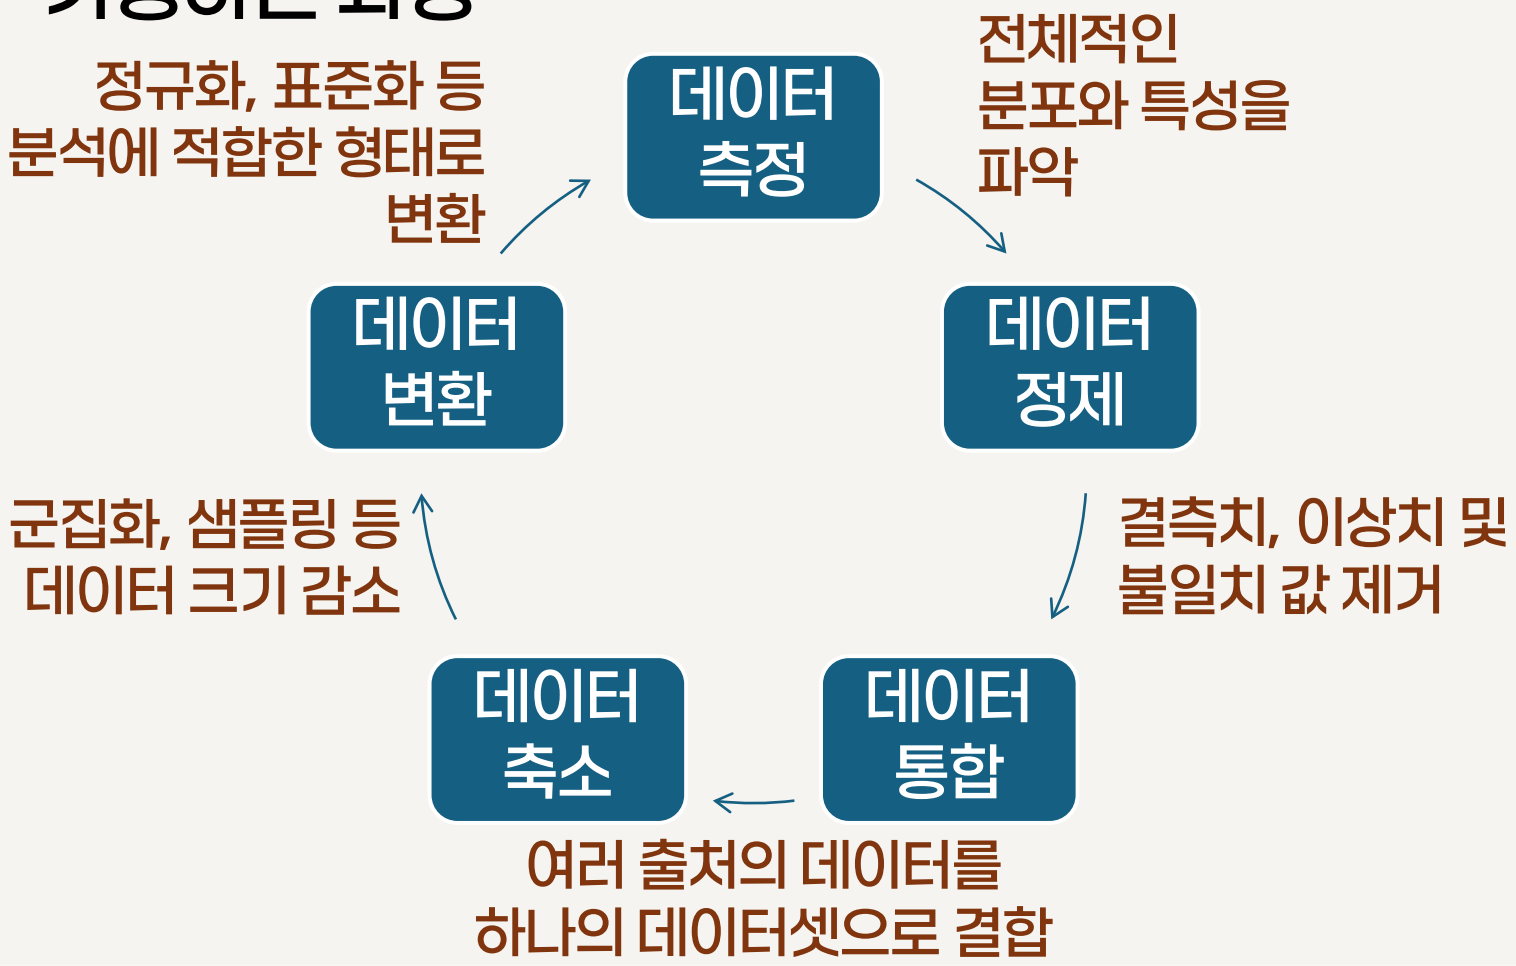
데이터 수집 및 저장	데이터 전처리	데이터 분석	데이터 시각화
• 수집 대상 데이터 정의 • 데이터 수집 경로 선정 • 데이터 수집 자동화 • 데이터 저장 방식 선택	• 결측치와 이상치 처리 • 중복 데이터 제거 및 필터링 • 데이터 축소 및 변환	• 탐색적 데이터 분석 수행 • 분석 계획 수립 • 데이터 분석 기법 선택 • 데이터 분석 결과 도출	• 기초 통계량 시각화 • 데이터 유형별 시각화 • 시각화 도구 활용

데이터 수집 및 저장 단계

- 단순히 데이터를 모으는 것이 아니라, 수집한 데이터를 효율적으로 보관하고, 분석 목적에 적합한지 검토
- 데이터 수집 과정
  - 데이터 분석 목표를 기반으로 데이터 수집 목적 설정
  - 데이터 출처 결정
    - 내부 데이터: 기업이나 기관 내부에서 생성된 데이터
    - 외부 데이터: 정부의 공공 데이터, 소셜 미디어 데이터, 연구 기관의 통계 자료 등 기관 외부에서 제공하는 데이터
  - 데이터 수집 방법 결정
    - 파일 다운로드, 데이터베이스, 웹 스크래핑, API, 센서(IoT)

데이터 전처리 단계

- 데이터를 정리하고 변환하여 분석이 가능하도록 가공하는 과정



데이터 분석 단계

- 통계 기법, 데이터 간의 관계 파악, 예측 모델 구축 등의 데이터 분석 기법 적용

EDA

- 데이터의 분포와 특성을 이해하기 위한 과정
- 데이터를 요약하고 시각적으로 표현
- 주요 패턴과 이상치 파악, 변수 간 관계 분석

통계 분석

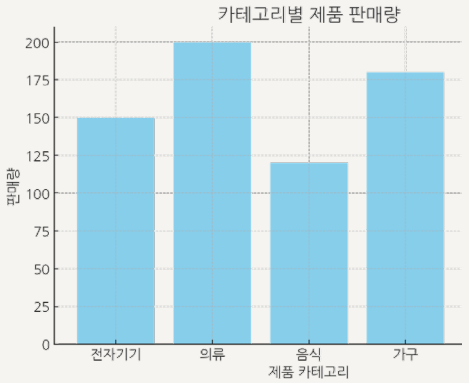
- 평균, 중앙값, 표준편차 등 기본 기술 통계
- 가설 검정, 상관 분석, 회귀 분석 등 통계 기법 활용
- 데이터에서 발견된 패턴의 통계적 유의성 검증

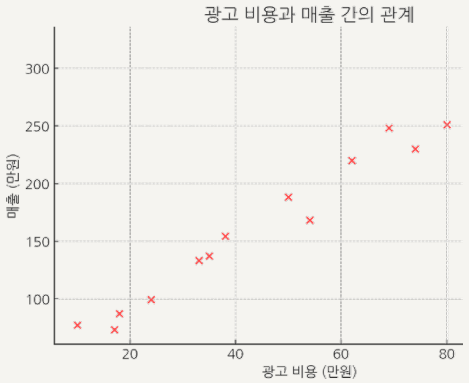
머신러닝 및 딥러닝

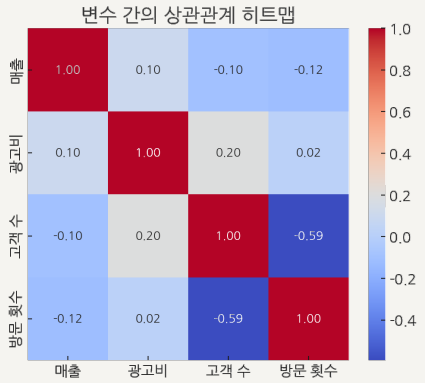
- 과거 데이터를 학습하여 미래 예측이나 데이터 분류
- 자동화된 의사결정 모델 구축
- 복잡한 패턴을 발견 및 대규모 데이터에서 인사이트 도출

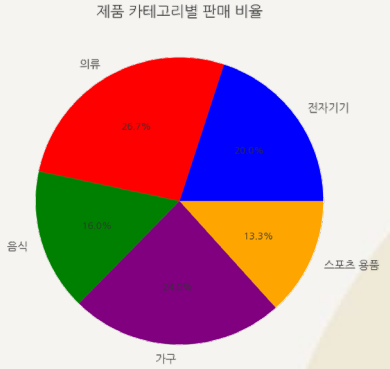
데이터 시각화 단계

- 데이터셋의 정보와 관계를 그래프, 차트, 다이어그램 등의 시각적 요소를 활용하여 직관적으로 표현
- 데이터 시각화의 역할
  - 데이터 탐색과 패턴 발견
  - 복잡한 데이터의 요약
  - 데이터 분석 결과 전달

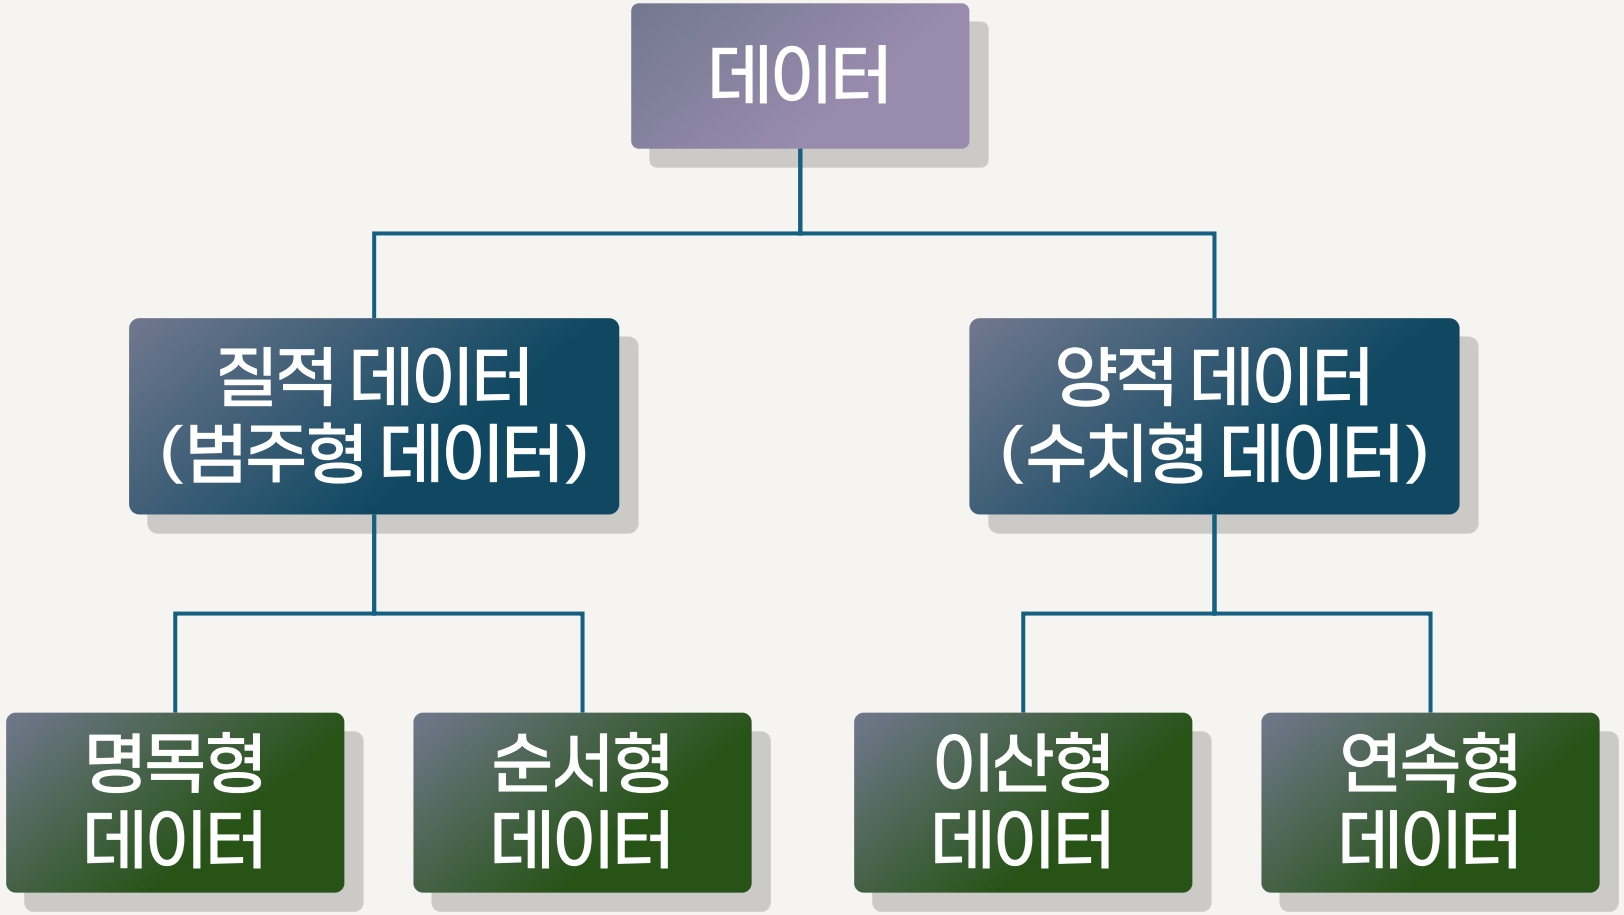








데이터의 속성에 분류



데이터 형태에 따른 분류

- 정형 데이터 (structured data)
  - 일정한 규칙과 구조를 갖춘 데이터
  - 행과 열로 구성된 표 형태로 관계형 데이터베이스에 저장
- 비정형 데이터 (unstructured data)
  - 정해진 구조 없이 자유로운 형태로 존재하는 데이터
  - 문장, 이미지, 영상, 음성 등 다양한 형식
  - 분석이 어려운 반면 소비자 감정 및 행동 패턴 등 많은 정보량
- 반정형 데이터 (semi-structured data)
  - 정형 데이터와 비정형 데이터의 중간 형태
  - 데이터 항목 간 일정한 규칙이나 구조가 존재하나, 완전히 테이블 형태로 고정 불가능

03

오픈소스의 이해



오픈소스의 개념

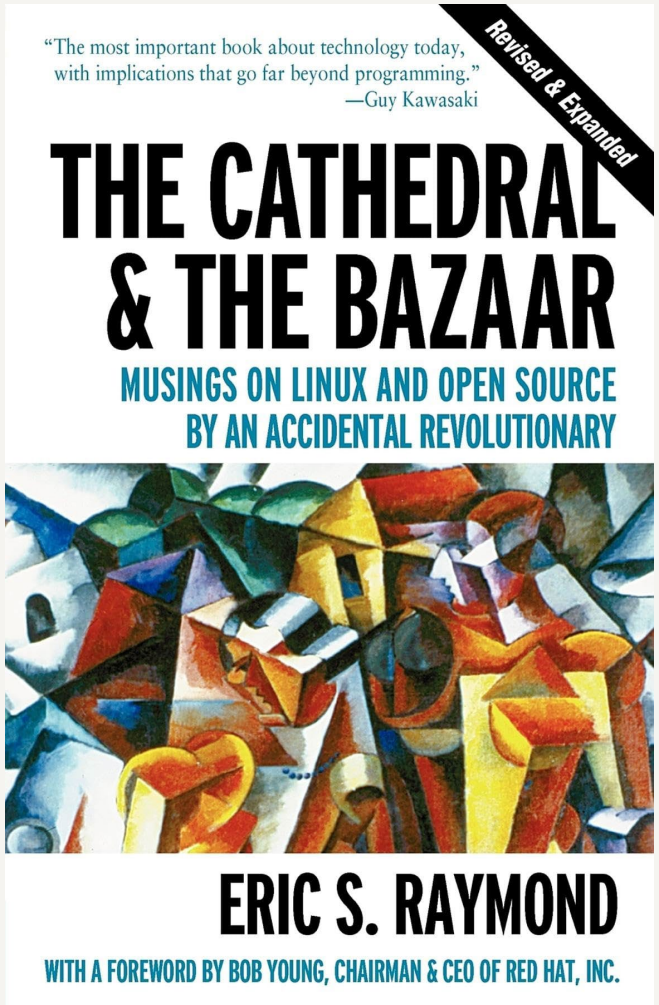
- 인류의 지적 자산(소스코드와 데이터)을 개방함으로써 더 많은 사람들과 함께 공유하고 협력하겠다는 철학
- 1960년대 미국 대학가의 반문화 운동과 해커 문화에서 시작되어 "정보는 자유로워야 한다"는 신념으로 발전
- 오픈 철학의 확장
  - 소스코드가 공개되어 누구나 자유롭게 접근, 사용, 복제, 수정, 재배포할 수 있는 소프트웨어 분야
  - MIT OCW, MOOC 등 대학 강의를 무료로 공개
  - 정부와 공공기관이 보유한 데이터를 시민들에게 공개

리처드 스톨먼(RMS: Richard Mathew Stallman)



- 컴퓨터 과학자이자 소프트웨어 자유론의 강한 지지자
- 자유 소프트웨어 운동의 중심 역할 및 오픈소스 소프트웨어 초석 마련
  - GNU 프로젝트 시작
  - 자유 소프트웨어 재단(FSF) 설립
- GNU 시작의 계기
  - 사건1: PDP-10에 설치할 DEC사의 OS 사용에 복사뿐만 아니라 자료 또한 유출하지 않겠다는 NDA를 요구
  - 사건2: 유닉스 라이센스 비용은 카피당 $99(소스코드 포함)에서 $250,000로 올림

FSF의 확장



- 에릭 레이몬드의 1997년 에세이 '성당과 시장 '
- FSF에서 또 다른 분수령
- 두 방식의 개발 모델
  - 성당: 핵심 그룹이 개발을 수행하는 독점적 SW 개발에서 전형적으로 나타나는 폐쇄적 하향식 접근 방식
  - 시장: 네트워크를 통해 무료로 공유되는 개방적 공개 개발 방식
- Open Source Initiative(OSI) 설립의 시초

지속 가능 모델?

- 성공적 OSS 개발을 위해 개발자의 지속 참여 필수
- 기업의 관점
  - OSS는 개발 비용을 외부화, 초기 개발 비용을 감소
  - 기업의 코드 공개가 다른 개발자의 코드 공개를 유도할 수 있으므로, 기업은 직간접적으로 OSS 개발에 참여
- 개인의 관점
  - 내재적 동기
    - 취미 생활로서, 수정 사항 공유 및 선물하는 즐거움
    - 내가 도운 대로 상대방도 도울 것이라는 일반화된 호혜성
  - 외재적 동기
    - OSS 개발자로서의 명성은 노동 시장에서 신호 효과 유도

파이썬과 오픈소스 환경

- 오픈소스 철학을 기반으로 설계되고 발전해온 언어
- 언어 자체와 이를 둘러싼 수많은 라이브러리, 프레임워크, 커뮤니티 활동이 모두 오픈소스 방식으로 운영
- 개발 환경
  - IDLE: 기본 제공되는 개발 환경
  - Jupyter Notebook: 코드를 블록(셀) 단위로 실행
  - 구글 Colab: 별도 설치 없이 웹 브라우저에서 바로 사용
- Selenium, lxml, Pandas, statsmodels, Matplotlib, Seaborn, Scikit-learn 등 다양한 오픈소스 라이브러리 사용 가능

정리하기

- 데이터 분석은 데이터를 정리·처리·변환하여 유의미한 정보를 도출하는 과정이다.
- 데이터 분석은 인사이트와 가치 창출, 비효율적 프로세스 개선, 사회적 문제 해결 데이터 기반 의사결정을 가능하게 한다.
- 데이터 분석의 3요소는 컴퓨터과학, 도메인 지식, 통계 및 수학이다.
- 데이터는 속성, 형태에 따라 다양하게 분류되며 그에 따른 분석 방법이 필요하다.
- 오픈소스는 소스코드나 데이터가 공개되어 누구나 자유롭게 접근, 사용, 수정, 재배포할 수 있다
- 파이썬 프로그래밍 환경은 IDLE, Jupyter Notebook, Google Colab을 등이 있다.
- 데이터 분석에 필요한 파이썬 패키지는 Selenium, lxml, NumPy, Pandas, Statsmodels, Matplotlib, Seaborn, Scikit-learn 등 오픈소스 라이브러리가 있다.

02강

다음시간안내

데이터 분석을 위한 파이썬 프로그래밍 1

