오픈소스 기반 데이터분석

05강

데이터 저장

컴퓨터과학과 정재화교수



학습목차

1. 데이터 저장의 이해
2. Pandas DataFrame의 이해



01

데이터 저장의 이해



데이터 저장의 필요성

- 수집한 데이터를 영구적으로 사용할 수 있도록 적절하게 관리하는 과정
  - 저장 방식은 데이터의 크기, 형태, 접근 빈도, 분석 목적 등에 따라 상이
  - 저장 방식 별 특징, 장단점에 대해 구체적 이해 필요
- 데이터 저장 방식: 파일
  - OS의 파일 시스템 상에서 데이터를 독립적인 단위로 저장
  - 텍스트 파일, CSV 파일, JSON 파일 등 다양한 형태 가능
  - 호환성이 뛰어나고 여러 환경에서 파일 읽기/쓰기 가능
  - 대규모 데이터 처리에 비효율적이고 데이터 무결성과 보안 측면에서 취약

CSV(Comma Separated Version)

- MS 엑셀, 구글 스프레드시트, 데이터베이스 등 다양한 프로그램과 연동이 용이
- DataFrame은 CSV와 구조적 유사성으로 CSV 파일로 변환하여 저장하는 방법을 제공

```
1 student_id,database_score,cloudcomputing_score,
                                    python_score,watch_rate
2 101,85,78,92,0.95
3 102,76,82,78,0.87
4 103,92,95,85,0.99
5 104,63,70,75,0.8
6 105,88,84,91,0.93
```

JSON(JavaScript Object Notation)

- 계층 구조를 가진 데이터를 저장하는데 유용
- json 또는 pandas 라이브러리를 사용하여 데이터를 JSON 파일로 저장 가능

```
[
    {
        "이름":"홍길동",
        "나이":25,
        "거주지":"서울",
        "관심사":[
            "프로그래밍",
            "데이터 분석",
            "여행"
        ]
    }
]
```

데이터 저장 방식: 데이터베이스

- 수집한 정보를 효율적으로 보관하고 필요할 때 신속하게 활용하기 위한 체계적인 저장 시스템



- 데이터베이스의 종류
  - RDBMS: 데이터를 행과 열로 구성된 테이블 형태로 저장하고 SQL을 통해 데이터의 CRUD 수행
  - 비RDBMS: 문서, 키-값의 쌍, 그래프 등 다양한 유연한 방식의 저장 구조를 지원하고 유사 SQL 및 API를 통해 조작
    - MongoDB, Cassandra, Redis, Elasticsearch 등이 대표적인 비관계형 데이터베이스

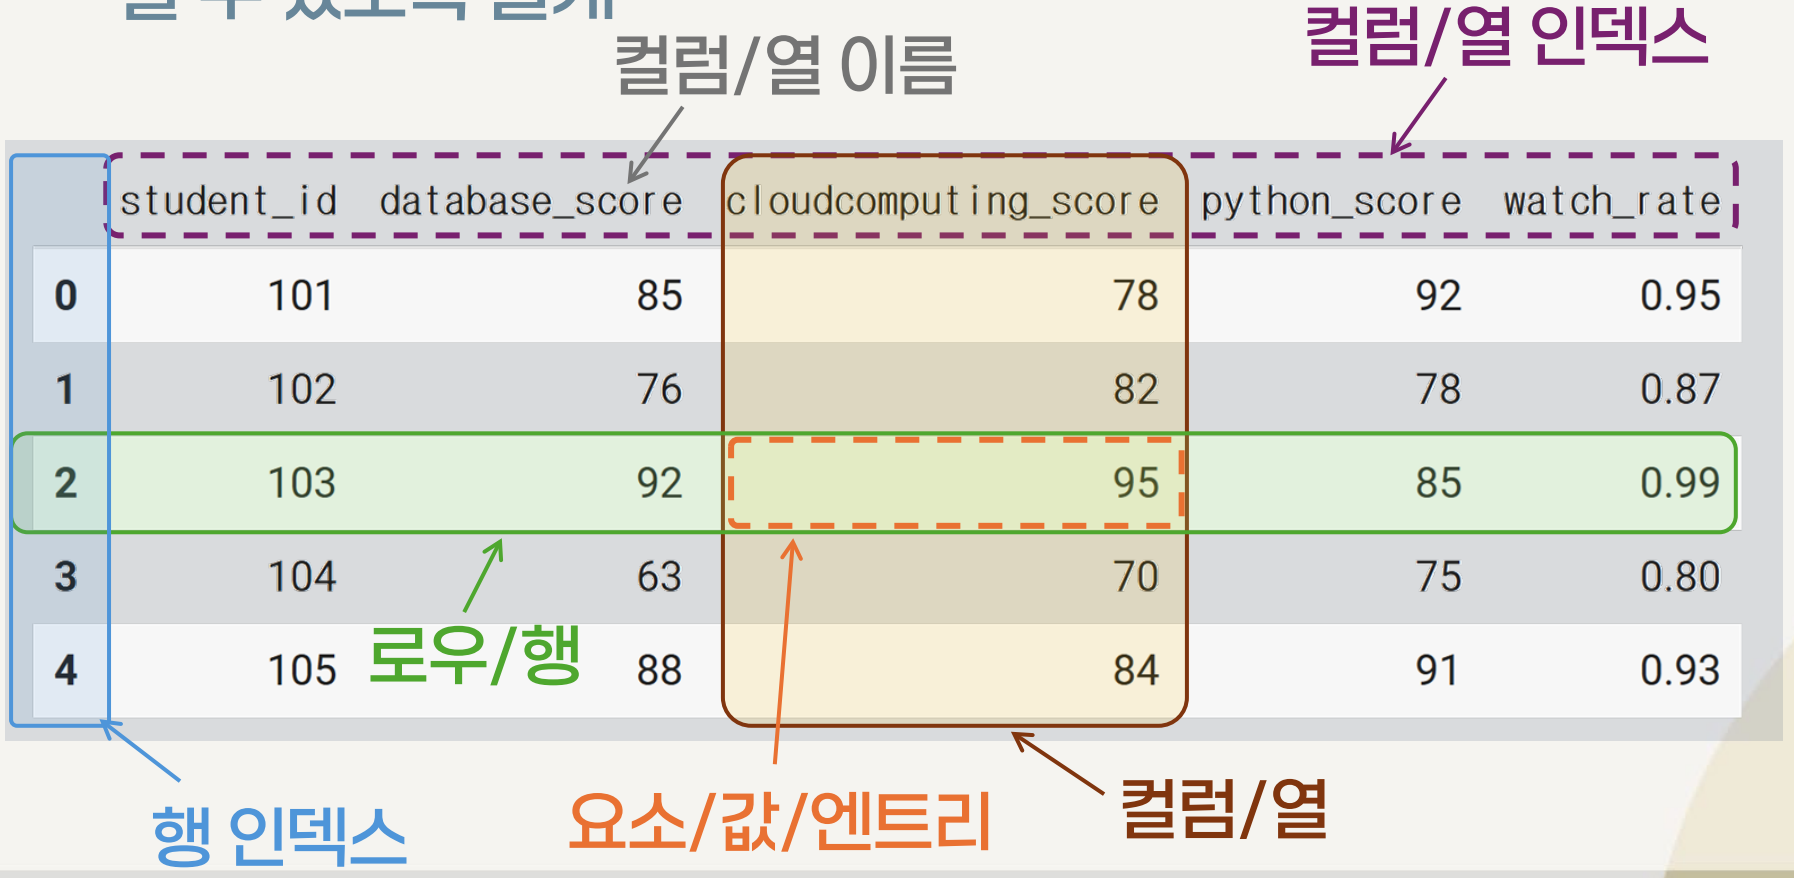
02

Pandas DataFrame의 이해



DataFrame의 구조

- 2차원 테이블 형태의 자료구조
  - 표 형태 그 이상으로, 데이터를 효율적으로 처리하고 분석할 수 있도록 설계



	student_id	database_score	cloudcomputing_score	python_score	watch_rate
0	101	85	78	92	0.95
1	102	76	82	78	0.87
2	103	92	95	85	0.99
3	104	63	70	75	0.80
4	105	88	84	91	0.93

DataFrame의 인덱스

	student_id	database_score	cloudcomputing_score	python_score	watch_rate
0	101	85	78	92	0.95
1	102	76	82	78	0.87
2	103	92	95	85	0.99
3	104	63	70	75	0.80
4	105	88	84	91	0.93

- DataFrame 생성 시 정수형 인덱스가 자동 부여
  - set_index( ) 메소드를 사용하여 문자열, 날짜 등 특정 컬럼을 인덱스로 설정 가능
  - 특정 행을 빠르게 찾고, 데이터를 조작하는 데 사용
- 데이터는 DataFrame 내부에 NumPy의 배열 형태로 저장
  - 데이터를 효율적으로 저장하고 고속의 수치 연산 수행

DataFrame 활용 예

```
import pandas as pd

data = {
    "이름": ["김철수", "이영희", "박민수", "최지훈"],
    "학년": [1, 2, 3, 4],
    "학점": [4.2, 3.8, 4.5, 3.9]
    "학과": ["컴퓨터학", "경영학", "농학", "교육학"],
    "동아리": ["프로그래밍", "독서", "로봇", "봉사"]
}
df = pd.DataFrame(data)

print("index:\n", df.index)
print("\ncolumns:\n", df.columns)
print("\nvalues:\n", df.values)
print("\nrows:\n", df.values.tolist())
```

DataFrame 생성 함수

- 딕셔너리, JSON, CSV, 데이터베이스 등 다양한 형태의 원시 데이터(raw data)를 DataFrame으로 변환

데이터 유형	메소드명	설명
딕셔너리	from_dict()	딕셔너리를 변환. 키는 열 이름, 값은 열 데이터로 설정
시퀀스(리스트, 튜플, 딕셔너리)	from_records()	레코드(리스트, 튜플, 딕셔너리)의 시퀀스를 변환
CSV	read_csv()	CSV 파일에서 변환
JSON	read_json()	JSON 파일 / 문자열에서 변환
엑셀 파일	read_excel()	엑셀 파일에서 변환
HTML	from_html()	HTML 테이블 데이터를 변환
클립보드	from_clipboard()	클립보드(복사한 데이터)에서 변환
관계형 DB	from_sql()	SQL 결과 또는 DB 테이블에서 변환

DataFrame의 저장

- 데이터 수집하고 데이터 분석 후
  - 데이터 분석 결과를 적절한 형태로 저장하여 보관
  - 다른 시스템과 공유하는 과정이 필요
- DataFrame 객체는 저장된 데이터를 다양한 형식으로 저장하여 분석 결과를 활용하는 데 필요한 메소드 제공
  - to_로 시작하는 저장 메소드
  - DataFrame의 내용을 CSV, JSON, 엑셀, 데이터베이스 등 각기 다른 파일 형식이나 데이터 구조로 변환·저장
  - 파일 형식 별 특징과 장·단점 이해 요구

DataFrame의 저장

메소드	설명
to_csv()	CSV 파일로 저장
to_json()	JSON 파일 또는 JSON 문자열로 저장
to_excel()	엑셀 파일(.xlsx)로 저장
to_html()	HTML 테이블 형식으로 변환
to_sql()	관계형 데이터베이스(SQL 테이블)로 저장
to_clipboard()	클립보드에 복사
to_dict()	파이썬 딕셔너리(dictionary)로 변환
to_string()	문자열로 변환하여 출력
to_markdown()	마크다운(markdown) 형식의 문자열로 변환

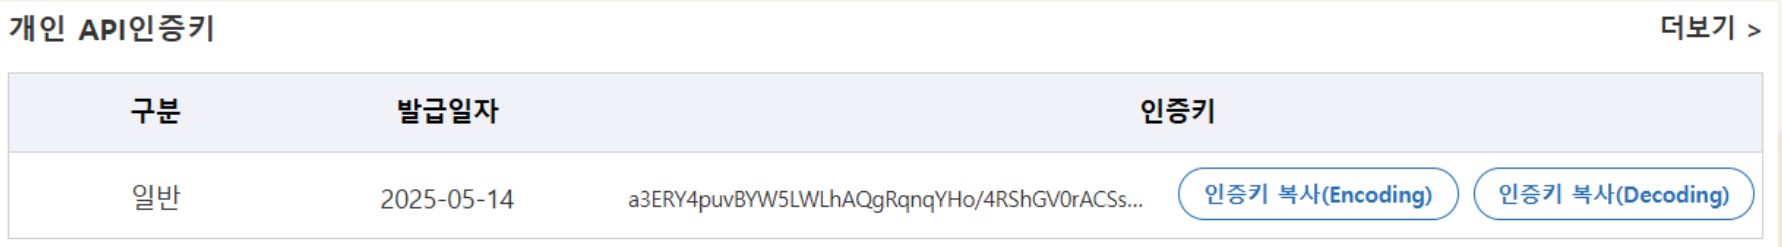
개념 정리 실습

- 공공데이터포털(data.go.kr)의 API를 활용하여 대기오염 정보를 수집하고, 분석 가능한 형태로 가공하는 과정을 실습
  - 공공기관이 보유한 데이터를 제공하는 통합 플랫폼
  - 교통, 환경, 보건, 문화 등 광범위한 분야의 데이터를 쉽게 활용할 수 있도록 개방

단계	주요 내용	사용 도구 / 방법
1. API 사용 준비	- 공공데이터포털 가입 - 대기오염정보 API 신청 - 인증키 발급	https://www.data.go.kr
2. 데이터 수집 및 변환	- API 호출 - JSON 데이터 수신 - DataFrame 변환	- requests 라이브러리 - Pandas 라이브러리
3. 데이터 저장	- CSV 형식 저장 - JSON 형식 저장 - Excel 형식 저장	- DataFrame 메서드

개념 정리 실습 – API 키

- 외부 서비스와의 통신을 위해 제공되는 인증 수단으로, 일반적으로 데이터 수집을 위한 API 호출 시 필요
  - 외부 서버에 접근할 수 있도록 허가받는 고유한 문자열
- 주의사항
  - 외부에 노출되지 않도록 철저히 관리(사용량 제한을 초과)
  - 사용량을 모니터링하고 적절한 수준에서 관리
  - 깃허브나 공개 저장소에 API 키를 업로드하지 않도록 주의



정리하기

- 수집한 데이터를 적절한 형태로 저장하여 보관하거나 공유해야 한다.
- 데이터의 크기, 형태, 접근 빈도, 분석 목적에 따라 저장 방식이 달라진다.
- 파일은 CSV, JSON, Excel 등 다양한 형식으로 저장할 수 있는 범용적 저장 방식이다.
- 파일은 대규모 데이터 처리에 비효율적이고 데이터 무결성과 보안 측면에서 취약하다.
- pandas는 데이터 분석을 위한 핵심 라이브러리로 DataFrame 객체를 제공한다.
- DataFrame은 딕셔너리, 리스트, 파일 등 다양한 데이터 소스에서 생성할 수 있다
- DataFrame은 데이터를 CSV, JSON, Excel 등 다양한 형식으로 저장할 수 있다.

06강 데이터 전처리 1

다음시간안내

