오픈소스 기반 데이터분석

06강

데이터 전처리 1

컴퓨터과학과 정재화교수



학습목차

1. 데이터 전처리의 이해
2. Pandas를 이용한 데이터 측정



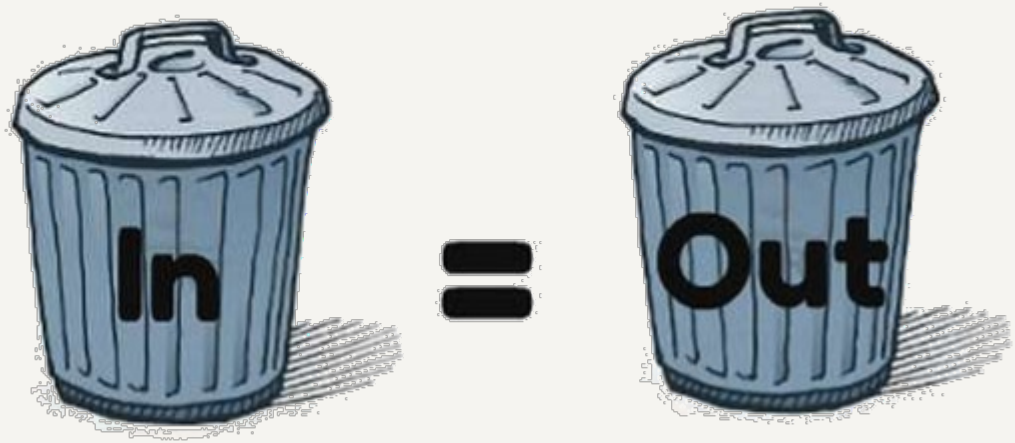
01

데이터 전처리의 이해



데이터 전처리의 필요성

- GIGO(Garbage In, Garbage Out)



  - 잘못되거나 부정확한 데이터를 입력하면, 어떤 정교한 분석 기법을 적용하더라도 잘못된 결과가 출력된다는 사실을 함축
  - 데이터의 품질 향상을 통해 분석 결과의 질을 향상시키기 위한 방안이 요구

데이터 전처리 대상 데이터

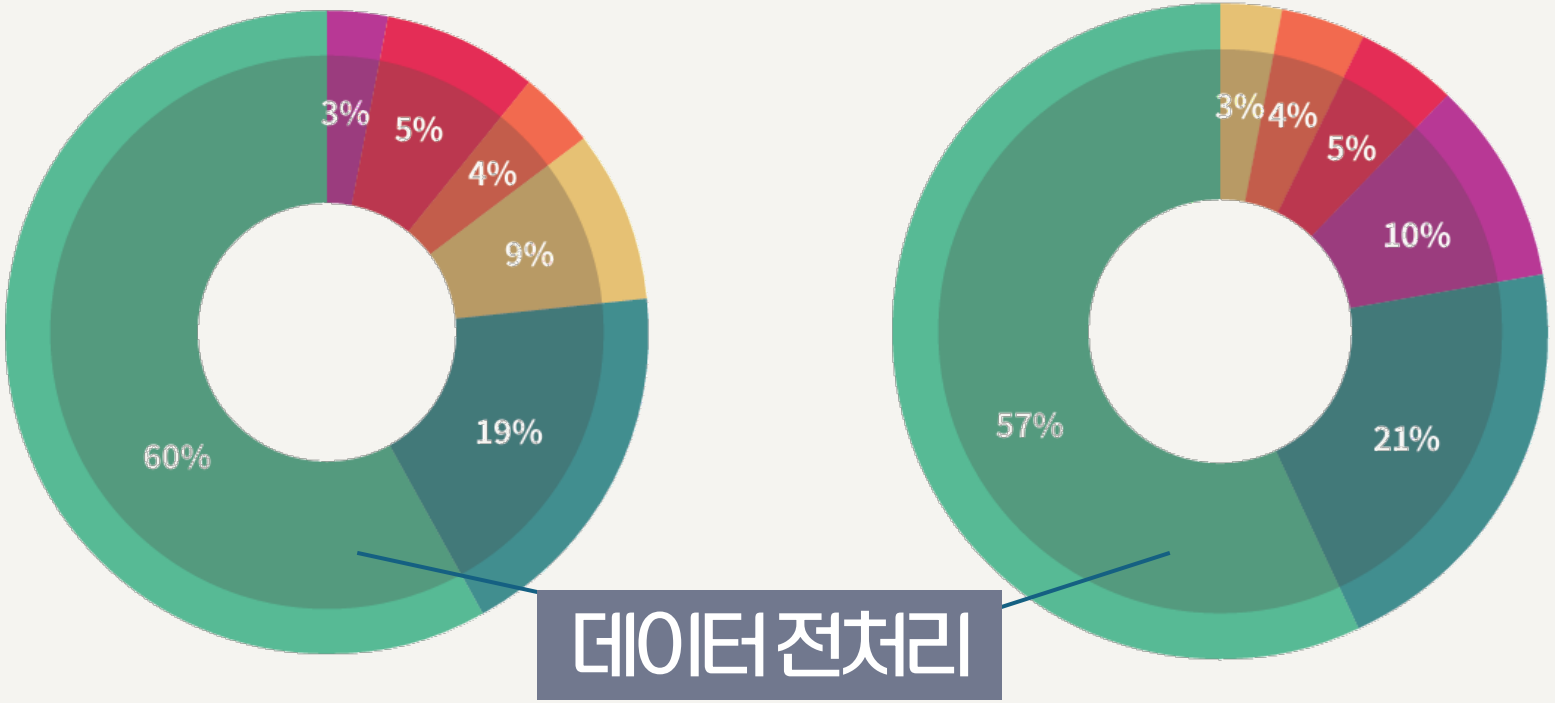
```
1  지점,상품명,가격,판매수량,세일광고여부
2  인천,태블릿,,102.0,N
3  수원,mouse,오류,120.0,Y
4  대구,TV,600000.0,139.0,
5  부산,스마트폰,50000.0,147.0,Y
6  울산,모니터,400000.0,133.0,N
7  수원,스피커,50000.0,-10.0,Y
8  창원,키보드,,47.0,N
9  대전,TV,400000.0,73.0,Y
10 인천,노트북,1000000.0,149.0,N
11 창원,스마트워치,300000.0,,N
12 대구,마우스,600000.0,71.0,Y
13                          ⋮
```

데이터 전처리의 필요성

- 정교한 데이터 분석 결과를 얻기 위해 데이터 분석에 다양한 변화 발생
  - 사용되는 데이터의 규모가 점차 증가
  - 신기술의 대중화로 다양하고 새로운 유형의 데이터 수집
  - 여러 이질적인 소스로부터 데이터 수집
- 불필요/불일치/중복 데이터, 결측치, 이상치 등이 포함
- 데이터의 품질 향상을 통한 분석 결과의 질을 향상
  - 결측치, 이상치, 값 불일치 등 데이터의 품질을 저하시키는 요인 제거
  - 데이터 정제, 통합, 축소, 변환과 같은 전처리 과정을 통해 데이터의 정확성과 일관성을 향상

데이터 전처리의 위상

- 2021년 Forbes가 데이터 과학자 80명에게 설문
  - Cleaning Big Data: Most Time-Consuming, Least Enjoyable Data Science Task, Survey Says

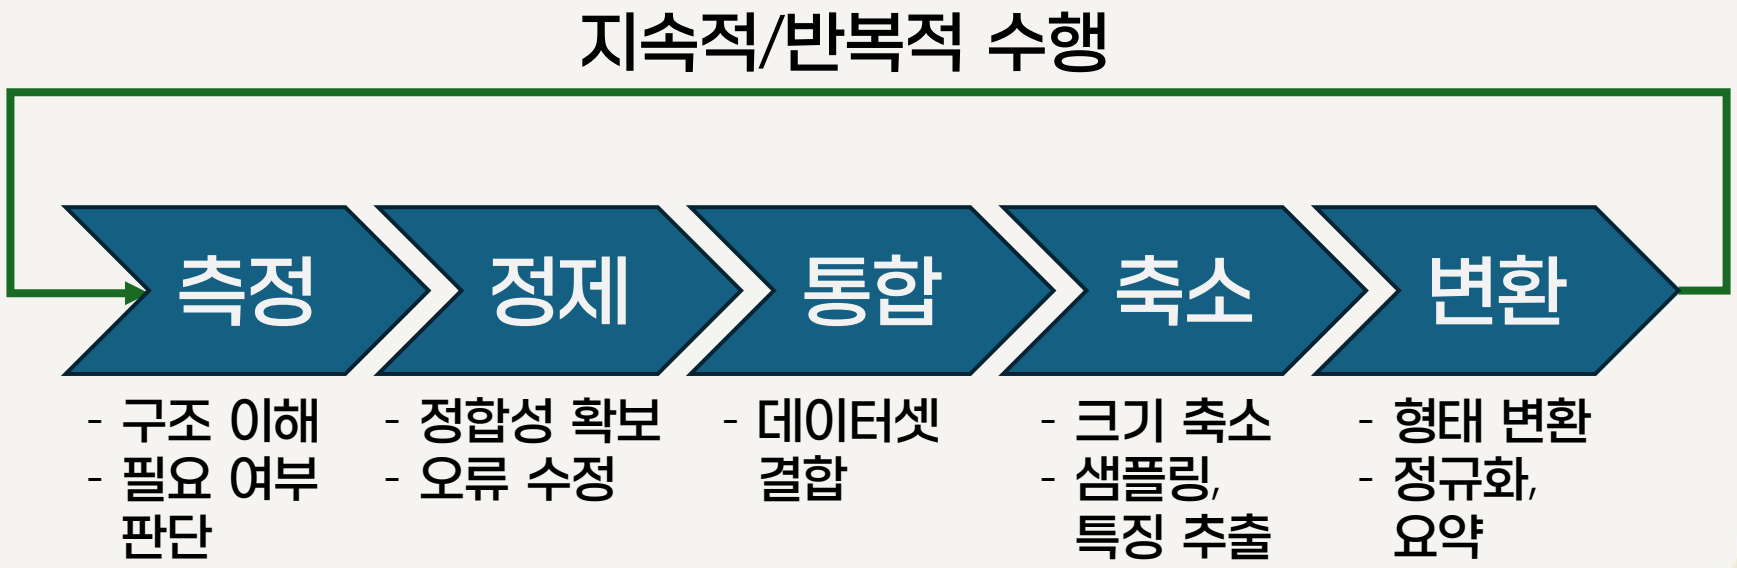


많은 시간이 소요되는 단계는?

가장 힘든 단계는?

데이터 전처리의 정의

- 데이터 분석에 앞서 원시 데이터(raw data)를 정제하고 변환하여 분석에 적합한 형태로 만드는 일련의 작업
  - 데이터 분석의 전 단계에서 수행되며, 데이터의 정확성과 신뢰성을 확보



데이터 전처리의 어려움

- 방대한 데이터 양
  - 수치형 데이터뿐만 아니라, 텍스트, 이미지, 로그 파일 등 다양한 형식이 존재
- 주관적 판단의 개입 여지
  - 정해진 정답이 없으며, 상황에 따라 적절한 결정
- 다양한 처리 방법
  - 처리 방법이 고정되어 있지 않으며, 다양한 접근법이 존재
- 시간과 노력 소모
  - 여러 단계를 반복적으로 확인하고 검토하는 과정

데이터 측정과 정제

- 데이터 측정
  - 다양한 측정 요소들을 활용하여 데이터의 구조와 특징을 정량적으로 파악
- 데이터 정제
  - 불완전성을 보완하고, 이상치를 탐지 및 완화하며, 데이터 간의 불일치성을 수정하는 일련의 과정
  - 결측치(missing values) 처리
    - 데이터셋 내에 특정 관측값이 누락되어 있는 상태
  - 이상치(outlier) 처리
    - 데이터에 포함된 불규칙한 변동이나 오류를 의미

데이터 통합, 축소 및 변환

- 데이터 통합(data integration)
  - 서로 다른 데이터 저장소로부터 데이터를 결합
  - 하나의 일관된 데이터 집합을 구축하는 작업으로, 중복과 불일치를 제거
- 데이터 축소(data reduction)
  - 방대한 데이터를 효율적으로 처리하기 위해 데이터의 크기를 줄이면서도 중요한 정보를 보존하는 과정
- 데이터 변환(data transformation)
  - 데이터의 구조나 값을 규칙에 따라 변환하여 분석이 효율적으로 수행되도록 지원

데이터 전처리의 예

```
1  import pandas as pd
2  from sklearn.cluster import KMeans
3
4  data = {'나이': [25, 30, 22, 35, 40, 50, 28, 33, 45, 55],
5          '소득': [3000, 4000, 2800, 5000, 6000, 7000,
6                   3200, 4500, 6200, 7200]
7          }
8
9  df = pd.DataFrame(data)
10 kmeans = KMeans(n_clusters = 3, random_state = 42)
11 df['군집'] = kmeans.fit_predict(df[['나이', '소득']])
12
13 print(df)
```

02

Pandas를 이용한 데이터 측정



데이터 측정

- 데이터의 형태, 값의 분포, 평균이나 중앙값 같은 대표값 등 데이터의 특성과 구조를 파악하는 과정
  - 이를 통해 데이터 전처리 및 분석의 방향을 결정
- pandas 라이브러리의 역할
  - 데이터의 저장 뿐만 아니라 평균, 분산, 최솟값, 최댓값 등 다양한 통계량 계산을 위한 기능 제공
  - 데이터의 상태를 요약하는 describe(), info() 메소드 사용
- 데이터 측정 요소
  - 데이터 측정 기준: 전체/레코드/그룹 별 측정
  - 요약 통계 지표: 데이터의 특징을 간단히 정리·이해
  - 기타 통계 지표: 데이터의 분포를 파악

요약 통계 지표

구분	지표	설명
중심 경향	평균	모든 값을 더한 후 개수로 나눈 값으로, 데이터의 대표성을 나타냄. 이상치에 민감
	중앙값	데이터를 크기순으로 정렬했을 때 한가운데 위치한 값으로, 이상치의 영향을 덜 받음
	최빈값	데이터에서 가장 자주 출현하는 값으로, 범주형 데이터 분석에 유용
분산 정도	분산	각 데이터 값이 평균에서 얼마나 떨어져 있는지를 제곱하여 평균 낸 값
	표준편차	분산의 제곱근으로, 데이터의 흩어진 정도를 원래 단위로 표현해 직관적
	범위	최댓값에서 최솟값을 뺀 값으로, 데이터의 전체 분포 폭을 파악하는 데 유용
	사분위수	하위 25%(Q1), 50%(Q2, 중앙값), 75%(Q3) 지점을 나타내며 데이터 분포를 시각적으로 이해하는 데 활용
	사분위 범위(IQR)	Q3에서 Q1을 뺀 값으로, 중앙 50% 구간의 범위를 나타내며 이상치 탐지에 활용

기타 통계 지표

지표	설명
합계	모든 데이터 값을 더한 값으로, 데이터 총합을 빠르게 확인할 때 사용
개수	데이터 항목 수를 나타내며, 결측치 여부 및 데이터 완전성 점검에 유용
최댓값	데이터 집합에서 가장 큰 값으로, 데이터의 상한 경계를 확인하는 데 도움
최솟값	데이터 집합에서 가장 작은 값으로, 데이터의 하한 경계를 확인하는 데 도움
왜도	데이터 분포가 평균을 중심으로 대칭적인지, 한쪽으로 치우쳤는지를 나타내는 지표
첨도	데이터 분포의 뾰족한 정도를 측정하며, 이상치의 빈도를 파악하는 데 유용

describe() 메소드

데이터 유형	제공 통계량	설명
수치형 데이터	count	데이터 개수 (결측치 제외)
	mean	평균
	std	표준편차
	min	최솟값
	25%	제1사분위수(Q1), 하위 25% 위치값
	50%	제2사분위수(Q2), 중앙값(median), 하위 50% 위치값
	75%	제3사분위수(Q3), 하위 75% 위치값
	max	최댓값
범주형 데이터	count	데이터 개수 (결측치 제외)
	unique	고유값(unique) 개수
	top	최빈값
	freq	최빈값의 빈도

describe() 메소드의 활용

```
1  data = {
2      'name': ['김민수', '이지영', '박준호', '최서연', '정도윤'],
3      'age': [25, 30, 28, 22, 35],
4      'city': ['서울', '부산', '인천', '서울', '대전'],
5      'score': [90, 85, 95, 80, np.nan]
6  }
7  df = pd.DataFrame(data)
8
9  print(df.describe())
10
11 print(df.describe(include=[np.number]))
12
13 print(df.describe(include=['object']))
```

정리하기

- 데이터 전처리는 원시 데이터를 분석에 적합한 형태로 정제하고 변환하는 과정이다.
- 입력 데이터의 품질이 분석 결과의 품질을 좌우한다.
- 데이터 측정은 특성 파악과 전처리 필요성 판단을 위한 기초 단계이다.
- 데이터 정제는 결측치, 잡음, 이상치 등을 처리하여 데이터 품질을 향상시킨다.
- 데이터 통합은 여러 소스의 데이터를 결합하여 일관된 데이터셋을 구성한다.
- 데이터 축소는 차원 축소, 데이터 압축 등을 통해 처리 효율성을 높인다.
- 데이터 변환은 정규화, 이산화 등을 통해 분석에 적합한 형태로 변형한다.
- describe( ) 메소드를 통해 데이터의 기술통계량과 구조를 파악한다.

07강

다음시간안내

데이터 전처리 2

