오픈소스 기반 데이터분석

12 강

정형 데이터 분석

컴퓨터과학과 정재화교수



정형 데이터의 특성과 분석 가치

- 행과 열로 구성된 명확한 구조
  - 각 열은 특정 속성을 의미하고 각 행은 개별 레코드를 표현
  - 데이터베이스, 스프레드시트, CSV 파일 등의 형태로 존재
- 분석 결과의 신뢰성과 높은 해석 용이성
  - 구조화된 형태
  - 집계, 필터링, 정렬 등의 기본적인 데이터 처리 작업부터 고급 통계 분석까지 다양한 분석 기법 적용 가능
- 다양한 데이터를 통합하여 객관적인 의사결정을 지원
  - 고객 행동, 운영 효율성, 시장 트렌드 등에 대한 인사이트 제공을 통해 전략적 의사결정의 기반

서울시 공공 자전거 '따릉이'

- 서비스 개요
  - 2010년 440대로 시작하여 2024년 현재 4만 5,000대 규모로 성장한 서울의 대표적인 친환경 교통수단
  - 2010년 캐나다의 '빅시(BIXI)' 시스템을 벤치마킹하여 시범 운영을 시작
- 운영 현황
  - 현재 서울 전역 2,700여 개의 대여소를 통해 운영
  - 누적 이용 건수는 1억 9,000만 건
  - 스마트폰 애플리케이션을 통해 간편하게 이용할 수 있으며, 대여 및 반납 시 시스템에 자동으로 이용 정보 기록

데이터 수집

- 수집 대상 데이터
  - 서울 열린데이터 광장(data.seoul.go.kr)
    - 서울특별시에서 운영하는 공공데이터 포털
    - 서울시의 교통, 환경, 복지, 안전, 인구 등 다양한 분야의 데이터를 표 형태 또는 API 형식으로 제공
    - CSV, JSON, XML 등 다양한 형식으로 다운로드 가능
- 따릉이의 2023년 4월 1일부터 30일까지의 일별 데이터를 활용
  - 대여 일시, 대여 및 반납 대여소 정보, 이용 시간, 이동 거리 등의 정보를 포함한 데이터를 사용
  - 시간대별, 요일별 이용 패턴을 파악하고, 외부 요인이 이용량에 미치는 영향 분석

시계열 데이터 분석

- 시계열 데이터
  - 시간의 순서에 따라 관측된 데이터의 연속
  - 일정한 시간 간격으로 수집되며, 각 관측값은 시간적 순서를 가지고 있어 이전 관측값들과 의존관계를 형성
  - 특정 현상이 시간에 따라 어떻게 변화하는지를 보여주며, 과거의 패턴을 분석하여 미래를 예측하는 데 활용
- 시계열 패턴 분석
  - 시간의 흐름에 따른 데이터의 변화를 관찰하고, 주기성이나 트렌드와 같은 시간적 특성을 파악하는 과정

데이터 연계

- merge 메소드
  - SQL의 join과 유사한 방식으로 두 DataFrame을 결합하는 기능
  - 공통된 키(key) 값을 기준으로 두 데이터셋의 정보를 하나로 통합하는 과정
  - 예) 자전거 이용량 데이터(daily_usage_df)와 강수량 데이터(rain_df)를 left join 방식으로 결합

```
1 merged_df = pd.merge(daily_usage_df, rain_df, how='left ' ,
                       left_on='기준_날짜', right_on='일시')
```

상관관계 분석의 이해

- 피어슨 상관계수(Pearson Correlation Coefficient)
  - 두 연속형 변수 간의 선형 관계를 측정하는 통계적 지표
  - Pandas의 corr() 메소드 사용
  - 피이슨 상관계수 r은 -1에서 1 사이의 값으로 표현
    - 1에 가까울수록 강한 양의 상관관계
    - -1에 가까울수록 강한 음의 상관관계
    - 0에 가까울수록 선형적 관계가 약함

$$r = \frac{\sum(x - \mu_x)(y - \mu_y)}{(\sigma_x \times \sigma_y)}$$

실습 프로젝트

- 서울시 '서울 열린데이터 광장' 과 기상청의 '기상자료개방 포탈' 의 데이터 분석
  - 날씨와 자전거 이용량의 상관관계를 분석

단계	주요 내용
1. 데이터 수집 및 전처리	- CSV 형태의 데이터 수집 - 기초 통계량 산출 - 결측치 처리 및 이상치 제거 - 날짜/시간 데이터 형식 변환
2. 데이터 분석	- 시계열 패턴 분석
3. 연계 분석	- 강수량 데이터와의 연계 분석 - 상관관계 분석

정리하기

- 정형 데이터는 테이블 형태로 구조화되어 있어 통계적 분석이 용이하다.
- 서울 열린 데이터 광장은 서울시의 교통, 환경, 복지, 안전, 인구 등 다양한 분야의 데이터를 표 형태 또는 API 형식으로 제공한다.
- 데이터 전처리에서는 결측치 처리, 이상치 제거, 날짜/시간 형식 변환 등을 수행한다.
- 요일별, 시간대별, 일자별 이용량 패턴을 분석한다.
- matplotlib, seaborn을 활용하여 분석 결과를 시각화한다.
- 원인이 파악되지 않는 데이터 분석 결과에 대해서는 급격한 변동 원인을 파악하기 위해 새로운 연관 데이터를 분석하여 해결할 수 있다.
- merge 함수를 활용하여 두 데이터셋을 결합한다.

13 강

다음시간안내

반정형 데이터 분석

