오픈소스 기반 데이터분석

13 강

반정형 데이터 분석

컴퓨터과학과 정재화교수



반정형 데이터의 개념과 특성

- 완전한 정형 데이터는 아니지만 일정한 구조와 규칙을 가진 데이터 유형
  - 월드와이드웹(WWW)의 탄생 이후 웹의 기본 구조로 자리잡은 형태
  - 지난 30여 년간 인터넷상의 거의 모든 정보가 반정형 데이터 형식으로 작성
- HTML, XML, JSON 등이 대표적인 반정형 데이터 형식
- 웹 데이터 분석, 대규모 언어 모델(LLM) 개발의 훈련 데이터, 데이터 분석/과학 연구 등에 응용

웹 스크래핑

- 웹 페이지 다운로드에서 끝나지 않고, 다운로드한 웹 페이지에서 원하는 데이터를 정확히 추출하는 과정
- 웹 스크래핑 관련 라이브러리
  - Selenium
    - 웹 브라우저를 자동화하여 동적 웹 페이지나 로그인이 필요한 페이지에 효과적으로 접근
    - 실제 웹 브라우저를 실행하여 클릭, 입력 등 사용자 행동 모방
  - lxml
    - HTML 문서를 파싱하고 원하는 데이터를 추출
    - HTML의 태그와 속성으로 구성된 구조를 해석하고 XPath를 통해 특정 요소를 선택적으로 추출

텍스트 데이터 분석

- 텍스트 데이터 전처리
  - 정규식을 활용한 특수문자 제거
  - 형태소 분석을 통한 품사 분리, 불용어 처리 등의 과정을 통해 텍스트 데이터를 분석 가능한 형태로 정제
- 키워드 분석
  - 단어 빈도 분석, 워드 클라우드 생성, 주요 키워드 추출을 통해 텍스트 데이터에서 의미 있는 정보를 추출
- 텍스트 분류 및 시각화
  - 대규모 언어 모델(LLM)을 활용한 텍스트 분류
  - 분류 결과 시각화, 인사이트 도출 과정을 통해 텍스트 데이터의 패턴 발견

lxml의 XPath

- XML 및 HTML 문서에서 특정 요소를 선택하는 데 사용되는 경로 표현 언어
  - 태그, 속성, 텍스트 등을 선택적으로 추출 가능

XPath 문법	설명
/	절대 경로: 루트 요소부터 시작
//	상대 경로: 현재 위치에서 모든 하위 요소 선택
.	현재 노드
@	속성 선택
text()	요소의 텍스트 값 선택
[]	조건 설정
*	모든 요소 선택

텍스트 정제

- 정규표현식
  - 기호와 문자 조합으로 특정 규칙을 가진 문자열을 찾는 체계
  - 문자를 선택하는 요소, 반복을 나타내는 요소, 문자 범위를 나타내는 요소로 구성
- 주요 정규표현식 패턴

패턴	설명
[^a-zA-Z0-9가-힣\s]	영문자, 숫자, 한글, 공백을 제외한 모든 문자
<[^>]*>	<로 시작하고>로 끝나는 모든 HTML 태그
\s	공백 문자 (스페이스, 탭, 개행 등)를 의미

형태소 분석

- 문법적인 의미를 가지는 최소 단위인 형태소로 텍스트를 분리하고, 각 형태소의 품사를 파악하는 과정
- 한국어는 교착어로서 하나의 단어가 다양한 어미나 조사와 결합하여 여러 의미를 표현할 수 있어 형태소 분석이 특히 중요
- Kiwi 라이브러리
  - 한국어 형태소 분석을 위한 최신 도구로, KoNLPy 등 기존 라이브러리보다 빠르고 정확한 분석 결과 제공
  - 문장의 핵심 의미를 담고 있는 명사를 추출하기 위한 목적으로 사용

게시글 분류

- 문서/문장을 미리 정의된 카테고리로 분류하는 작업
- 대량의 텍스트 데이터 분류를 위해 대규모 언어 모델 (LLM)이 도입
  - 문맥을 이해하고 생성할 수 있는 딥러닝 기반의 AI 모델
  - 텍스트 분류, 요약, 번역, 질의응답 등 다양한 자연어 처리 작업 수행 가능
- LLM 구축 환경
  - vLLM 라이브러리를 통해 LLM 모델 로드
  - Hugging Face의 모델 저장소에서 LG에서 개발한 EXAONE 3.5 버전의 2.4B 모델을 사용
  - 한국어 처리 능력이 우수하고 구글의 T4 GPU에서도 구동

실습 프로젝트

방송통신대학교 학과게시판의 글 제목을 수집하고 분석

- 웹 스크랩핑 구현 및 텍스트 데이터를 분석을 통한 텍스트 분류 및 시각화

단계	주요 내용
1. 데이터 수집 및 전처리	- Selenium을 활용한 웹 페이지 접근 - lxml을 이용한 HTML 파싱 - 게시글 제목 추출
2. 텍스트 데이터 전처리	- 정규식을 활용한 특수문자 제거 - 형태소 분석을 통한 품사 분리 - 불용어 처리
3. 키워드 분석	- 단어 빈도 분석 - 워드 클라우드 생성 - 주요 키워드 추출
4. 텍스트 분류 및 시각화	- LLM을 활용한 텍스트 분류 - 분류 결과 시각화

정리하기

- 반정형 데이터는 완전한 정형 데이터는 아니지만 일정한 구조와 규칙을 가진 데이터이다.
- 웹 페이지는 HTML(구조), CSS(스타일), JavaScript(동작)의 세 요소로 구성된다.
- Selenium, lxml, Xpath는 통해 동적 웹 페이지 크롤링에 효과적이다.
- Kiwi 라이브러리는 한국어 형태소 분석에 효과적이다.
- 정규표현식을 활용하여 특수문자를 제거하고 텍스트를 정제한다.
- 형태소 분석을 통해 문장을 품사 단위로 분리한다.
- 워드 클라우드는 단어의 출현 빈도에 따라 크기를 다르게 하여 시각화한다.
- 대규모 언어 모델(LLM)을 활용하여 게시글을 자동으로 분류할 수 있다.

14 강

다음시간안내

비정형 데이터 분석

