오픈소스 기반 데이터분석

14 강

비정형 데이터 분석

컴퓨터과학과 정재화교수

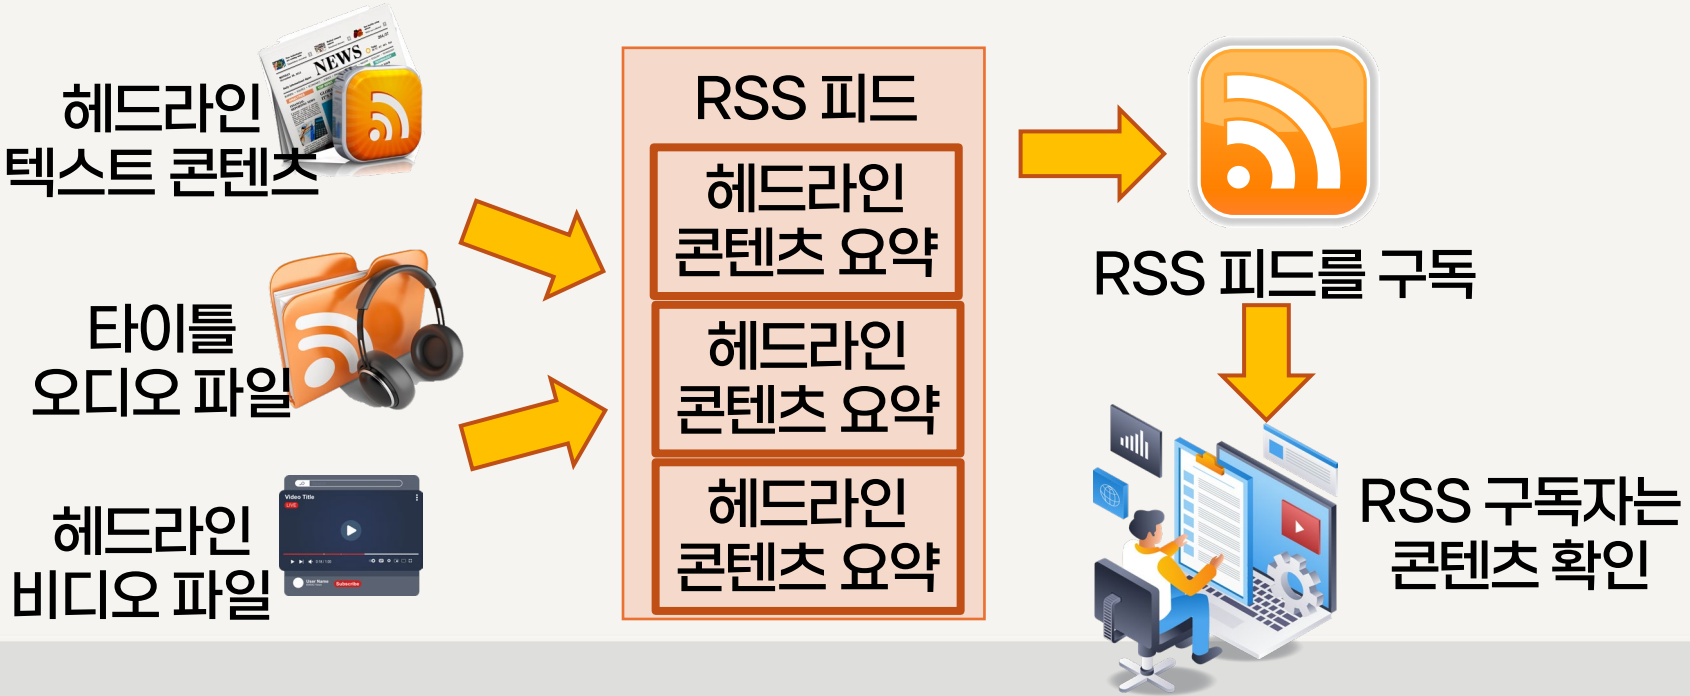


비정형 데이터의 이해

- 비정형 데이터의 정의
  - 일정한 형식이나 구조가 없이 저장된 정보
  - 이미지, 영상, 음성, 텍스트 등 다양한 형태로 존재
- 비정형 데이터의 특징
  - 정형 데이터에 비해 압도적인 데이터 양(전체 대비 70%)
  - 풍부한 정보를 담고 있으나 전통적 분석으로는 처리 제한
- 비정형 데이터의 가치
  - 소비자의 취향, 시장 트렌드, 사회적 변화 등 정보 내포
  - 기업의 의사결정, 마케팅 전략, 제품 개발 등에 활용 가능

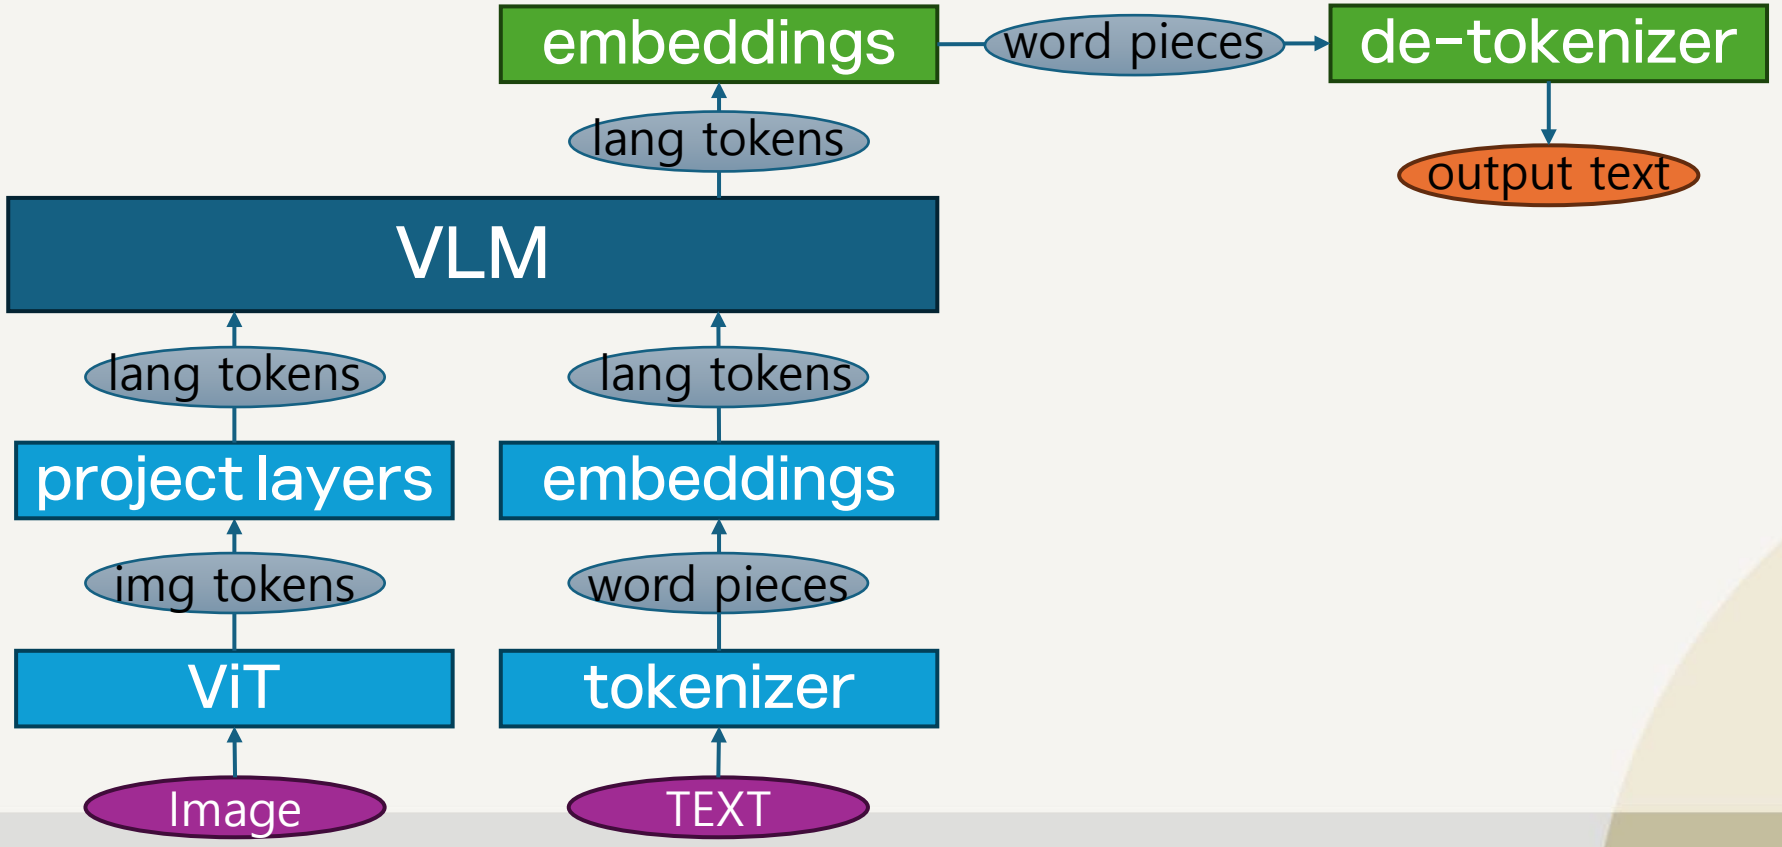
RSS를 활용한 데이터 수집

- RSS(Rich Site Summary)
  - 콘텐츠가 자주 갱신되는 사이트의 정보를 XML 포멧으로 구조화된 형식으로 제공하는 기술
  - 구조화된 방식으로 비정형 데이터를 실시간으로 수집할 수 있는 효율적인 메커니즘으로 사용 가능



시각 언어 모델(VLM)의 이해

- 이미지를 이해하고 이를 자연어로 설명하는 AI 모델
  - 이미지와 텍스트를 동시에 처리하는 멀티모달 AI 기술
    - "사람이 입은 옷의 스타일을 설명해 줘"와 같은 지시를 이해



토크나이저(tokenizer)

- 자연어와 기계어 사이의 번역기 역할
- VLM과 LLM에서 텍스트 입력을 처리하는 컴포넌트
  - 텍스트 분할
    - 자연어 텍스트를 모델이 처리할 수 있는 토큰(단어, 서브워드, 문자 수준 등)으로 분리
    - 언어별 특성을 고려한 분할 알고리즘 적용
  - 수치 변환
    - 각 토큰을 모델이 이해할 수 있는 숫자(ID)로 변환
    - 미리 정의된 어휘 사전에서 숫자 ID로 변환되며, 이는 모델이 훈련 중에 학습한 단어와 일치하는지 확인

프롬프트(Prompt)의 개념과 설계

- 모델에 제공하는 입력 텍스트로, 모델의 출력을 유도하는 지시문
  - 모델과의 대화를 시작하고 방향을 설정하는 역할
  - 질문, 명령, 맥락 정보 등 다양한 형태로 구성 가능
- 효과적인 프롬프트 설계 원칙
  - 명확하고 구체적인 지시 포함
  - 원하는 출력 형식과 스타일 명시
  - 필요시 예시 제공
  - 맥락 정보와 배경 지식 추가
  - 단계별 안내를 통한 복잡한 작업 분해

실습 프로젝트

- 패션 매거진의 사진 데이터를 활용하여 패션 트렌드를 분석
  - VLM, LLM 등 AI를 활용한 이미지 분류 및 보고서 작성

단계	주요 내용
1. 데이터 수집 및 전처리	- requests를 이용한 RSS 데이터 수집 - lxml을 이용한 XML 파싱 - 이미지 데이터 추출
2. 이미지 분석	- 프롬프트를 이용한 이미지 필터링 - 프롬프트를 이용한 스타일 분
3. 키워드 분석 및 보고서 작성	- 텍스트 전처리 - 색상 및 스타일 키워드 추출 - 워드 클라우드 분석 - 보고서 작성

정리하기

- CNN, VLM, LLM 등의 딥러닝 기술은 비정형 데이터를 해석하는 새로운 방법론을 제공한다.
- 필터링된 이미지를 대상으로 VLM을 활용하여 옷의 스타일, 색상, 트렌드 특징 등을 자연어로 설명하는 분석을 수행할 수 있다.
- VLM 기반 분석은 시각적 데이터를 풍부한 텍스트 정보로 전환하여 정성적 인사이트를 제공한다.
- LLM을 활용하여 스타일 분석 결과로부터 색상과 스타일 키워드를 한글로 추출하고, 정규 표현식 기반 전처리 과정을 통해 데이터를 정제한다.
- 프롬프트 설계는 시스템 역할 정의, 사용자 지시사항, 데이터 반복 제공, 생성 매개변수 조정을 포함하여 출력 품질을 높인다.
- 자동 생성된 보고서는 트렌드 요약, 스타일 경향, 색상 분석 등을 포함하며, 초기 분석 초안 또는 보고서 작성의 기반 자료로 활용될 수 있다.

15 강

다음시간안내

시계열 데이터 분석

